

Прогноз повторной покупки клиента

Online Retail II · задача customer retention для e-commerce

Цель проекта — построить модель, которая по истории покупок клиента оценивает вероятность его возврата в следующие 90 дней.

Описание датасета

Online Retail II

Датасет содержит реальные транзакции британского онлайн-магазина подарков.

Есть временная компонента: дата и время заказа.

Основной рынок — Великобритания.

- Период данных: декабрь 2009 — декабрь 2011
- Одна строка в исходных данных — товарная позиция в заказе
- Есть временная компонента: дата и время инвойса

Основные поля

InvoiceNo	StockCode	Description	Quantity
InvoiceDate	Price	Customer ID	Country

824k транзакций	5.9k клиентов	90 дней target-window
--------------------	------------------	--------------------------

Бизнес-задача

Что предсказываем

Сделает ли клиент повторную покупку в следующие 90 дней.

target = 1, если клиент вернулся в будущий период;
target = 0, если не вернулся.

Зачем это бизнесу

- выделять клиентов с высокой вероятностью возврата;
- находить клиентов, которых стоит удерживать;
- понимать, какие факторы связаны с повторной покупкой.

EDA: главные наблюдения

- Основной рынок — Великобритания.
- Выручка сезонна: сильные пики ближе к рождественскому периоду.
- Большинство заказов небольшие, но есть сильные выбросы.
- В данных есть оптовые клиенты и отменённые заказы.

Что это дало для модели

recency

frequency

revenue

сезонность

возвраты

аномалии

- **Recency**: чем меньше дней с последней покупки, тем выше шанс возврата.
- **Frequency**: регулярные заказы лучше описывают лояльность, чем одна крупная покупка.
- **Revenue**: выручка и средний чек помогают отделять ценных клиентов.
- **Сезонность и возвраты**: декабрьские покупки, отмены и оптовость нужно учитывать отдельно.

Главный вывод EDA: для прогноза важна не отдельная транзакция, а история активности клиента.

Признаки для baseline

Мы агрегировали транзакции до уровня клиента: одна строка = один **Customer ID**. Все признаки считались только по историческому окну до cutoff date.

Покупки, деньги и разнообразие	
total_orders	сколько уникальных заказов сделал клиент
purchase_items	сколько товаров куплено без учёта возвратов
purchase_revenue	общая положительная выручка клиента
avg_item_price	средняя цена товара в покупках
avg_quantity	среднее количество товара в строке транзакции
unique_products	сколько разных товаров покупал клиент
unique_descriptions	сколько разных товарных наименований покупал клиент
revenue_per_order	средняя выручка на один заказ
orders_per_active_day	интенсивность заказов за активный период клиента

Время и возвраты	
first_purchase	дата первой покупки в истории клиента
last_purchase	дата последней покупки до cutoff date
recency_days	сколько дней прошло с последней покупки
customer_age_days	сколько дней клиент уже наблюдается в данных
return_items	сколько товаров было возвращено: отрицательные Quantity
return_count	сколько отменённых заказов было у клиента
return_revenue	суммарная отрицательная выручка по возвратам
has_any_return	флаг: были ли у клиента возвраты или отмены
return_rate_items / orders	доля возвратов по товарам и заказам

Смысл baseline-фичей: описать RFM-логику клиента — давность последней покупки, частоту заказов, денежную ценность, разнообразие покупок и наличие возвратов.

Baseline-модели и метрика

Какие модели использовали

- **Logistic Regression** — простой и интерпретируемый линейный baseline.
- **Random Forest** — ансамбль деревьев, который ловит нелинейные зависимости и взаимодействия признаков.

Для baseline использовали клиентские агрегаты: давность, частоту, выручку, количество заказов и товаров.

Как оценивали качество

- **Метрика: ROC-AUC** — показывает, насколько хорошо модель ранжирует клиентов по вероятности возврата.
- Метрика удобна, потому что важны вероятности, а классы могут быть несбалансированы.
- Чем ближе к 1, тем лучше; 0.5 — почти случайное ранжирование.

Модель	ROC-AUC	Вывод
Logistic Regression	0.7888	сильная простая база
Random Forest	0.7996	лучший baseline за счёт нелинейностей

Baseline показал, что даже простые агрегаты по истории клиента уже дают хорошее качество прогноза повторной покупки.

Аномалии: признаки, которые добавили в модель

После поиска выбросов мы не удаляли клиентов автоматически, а добавили флаги аномальности как отдельные признаки.

Флаги отдельных методов		Согласованность методов	
iso_anomaly	флаг аномалии по Isolation Forest: клиент необычен относительно основной массы клиентов.	anomaly_methods_count	сколько ML-методов одновременно посчитали клиента аномальным.
lof_anomaly	флаг аномалии по LOF: клиент находится в менее плотной области, чем его ближайшие соседи.	anomaly_agreement	доля методов, которые согласились, что клиент является выбросом.
svm_anomaly	флаг аномалии по One-Class SVM: клиент оказался вне «нормальной» области поведения.	strong_anomaly	флаг сильной аномалии: клиент отмечен несколькими методами сразу.

Результат: аномалии в retail оказались не только шумом. Часть таких клиентов похожа на оптовых или нестандартно активных покупателей, поэтому мы оставили эти признаки как сигнал для модели.

Feature Engineering: какие новые признаки добавили

После baseline мы расширили клиентскую таблицу признаками, которые описывают категорию клиента, похожих клиентов, время покупки и бизнес-контекст.

Категориальные признаки

country_mode_te	Target Encoding страны: историческая вероятность возврата клиентов из самой частой страны клиента.
main_stock_code_te	Target Encoding основного товара: насколько часто возвращались клиенты с похожим главным товаром.
country_ohe_*	One-Hot Encoding популярных стран: отдельные флаги для крупных рынков.

Кодировки считались только на train, чтобы не было утечки target.

KNN-признаки похожих клиентов

knn_return_rate	какая доля похожих клиентов вернулась в следующие 90 дней.
knn_avg_revenue	средняя выручка ближайших похожих клиентов.
knn_avg_recency	средняя давность последней покупки у похожих клиентов.
knn_mean_distance	насколько клиент похож на ближайших соседей: меньше расстояние — типичнее профиль.

Временные признаки

last_purchase_month / hour	месяц и час последней покупки клиента.
last_month_sin/cos	циклическое кодирование месяца: декабрь и январь становятся близкими периодами.
last_hour_sin/cos	циклическое кодирование часа покупки.
weekend_share	доля покупок в выходные.
evening_share	доля вечерних покупок.
december_share	доля декабрьских покупок как сигнал сезонности.

Контекстные e-commerce признаки

recent_activity_share	какая часть заказов пришлась на недавний период.
order_frequency_30d	частота заказов в пересчёте на 30 дней.
products_per_order	сколько разных товаров в среднем покупает клиент за заказ.
descriptions_per_order	разнообразие товарных описаний на заказ.
return_pressure	насколько сильно возвраты выражены относительно покупок.
payday_period_share	доля покупок в условный период зарплат.

Метрики после новых признаков

Модель	ROC-AUC	Комментарий
Baseline Logistic Regression	0.7888	до новых признаков
Baseline Random Forest	0.7996	лучший baseline
FE Logistic Regression	0.7991	новые признаки помогли линейной модели
FE Random Forest	0.7975	почти без изменения

Вывод: feature engineering улучшил Logistic Regression, но не дал стабильного прироста для Random Forest.

Отбор признаков и стабильность

Feature selection	
FE LogReg all	0.7991
Selected LogReg	0.7976
FE RF all	0.7975
Selected RF	0.7976



Отбор признаков упростил модель почти без потери качества. По PSI наиболее нестабильным оказался customer_age_days — это ожидаемо, так как возраст клиента растёт вместе с календарным временем. Также сдвиг был у recency_days и признаков активности, поэтому их важно учитывать при интерпретации.

Интерпретация: SHAP — локальный клиент

SHAP показывает, какие признаки сдвинули прогноз выбранного клиента в сторону возврата. Положительный вклад — аргумент за класс 1.

Logistic Regression: главные вклады		
active_months	+1.76	— длительная активность сильнее всего повышает прогноз.
recency_days	+0.90	— недавняя покупка работает в сторону возврата.
orders_last_30d	+0.62	— были заказы в последнем периоде.
order_frequency_30d	+0.22	— высокая частота заказов.
orders_per_active_day	+0.22	— высокая интенсивность покупок.
knn_return_rate	+0.20	— похожие клиенты часто возвращались.

Random Forest: главные вклады		
order_frequency_30d	+0.07	— частота заказов повышает прогноз.
orders_per_active_day	+0.06	— интенсивность покупок за активный день.
recency_days	+0.06	— клиент покупал достаточно недавно.
purchase_revenue	+0.04	— высокая ценность клиента.
knn_avg_recency	+0.04	— похожие клиенты тоже недавно покупали.
active_months	+0.03	— клиент активен много месяцев.

Вывод: обе модели дают высокий прогноз по одной бизнес-логике — клиент активный, покупал недавно, часто делает заказы и похож на возвращающихся клиентов.

Интерпретация: LIME — правила для того же клиента

LIME объясняет прогноз через локальные правила: условие + вес. Положительный вес повышает вероятность возврата, отрицательный — снижает.

Logistic Regression: правила		
active_months > 5	+0.236	— клиент долго активен.
recency_days ≤ 47.75	+0.211	— покупка была недавно.
orders_last_30d > 0	+0.112	— есть недавние заказы.
lof_anomaly ≤ 0	+0.105	— поведение не похоже на локальный выброс.
country_ohe_Spain ≤ 0	-0.113	— отсутствие этого флага снижает прогноз.
return_rate_items > 0.01	-0.095	— доля возвратов немного мешает прогнозу.

Random Forest: правила		
order_frequency_30d > 0.57	+0.075	— частые заказы.
orders_per_active_day > 0.02	+0.062	— клиент покупает регулярно.
recency_days ≤ 47.75	+0.061	— недавняя покупка.
knn_avg_recency ≤ 54.35	+0.053	— похожие клиенты тоже активны.
purchase_revenue > 1961	+0.047	— высокая накопленная выручка.
knn_return_rate > 0.60	+0.014	— соседи часто возвращались.

SHAP и LIME согласуются: главные причины высокого прогноза — недавняя активность, частота заказов, выручка и поведение похожих клиентов.

SHAP-эмбеддинги и аномалии

Идея

Клиента можно описать не исходными признаками, а SHAP-вкладами: как именно модель объяснила его прогноз.

После PCA смотрим группы, сдвиги и необычные объекты.

Результат

$\approx 3\%$

SHAP-аномалий на train и test

Доли близкие: train 3.00%, test 2.76%. Массового сдвига между выборками не видно.


SHAP-кластеры

Кластер 0: активные клиенты		Кластер 1: менее активные	
Клиентов	1551	Клиентов	2645
Доля возврата	0.837	Доля возврата	0.205
Средняя выручка	4852	Средняя выручка	663
Avg recency	77 дней	Avg recency	283 дня

KMeans по SHAP-эмбедингам выделил два бизнес-интерпретируемых сегмента. DBSCAN при выбранных параметрах кластеров не нашёл.

Shapley Flow: граф взаимосвязей признаков

Размер узла = SHAP-важность, линия = корреляционная связь



Как читать граф

- **Узел** — признак модели
- **Размер узла** — SHAP-важность признака
- **Линия** — корреляционная связь
- **Центральный блок** — recency, частота заказов, выручка и KNN-признаки

Вывод:
модель опирается на связанный блок активности.

Shapley Flow и граф связей

Что делали

Построили граф признаков: размер узла — SHAP-важность, ребро — корреляция.

Получили flow-компоненты — связанные группы признаков.

Главный блок

Активность клиента, частота заказов, ресенсу, выручка, KNN-признаки.

0.2806

суммарная SHAP-сила компоненты

Модель опирается не на один признак, а на связанный блок клиентской активности.

Финальное сравнение и выводы

Эксперимент	ROC-AUC	Вывод
RF исходные признаки	0.7976	лучшее финальное решение
RF после удаления SHAP-аномалий	0.7959	аномалии содержали полезный сигнал
RF + SHAP-кластер	0.7808	кластер полезен для диагностики, но не как признак
LogReg только flow-компоненты	0.7967	компактное представление почти не теряет качество

Улучшить качество модели за счёт диагностических признаков не удалось. Удаление SHAP-аномалий снизило ROC-AUC с 0.7976 до 0.7959; добавление SHAP-кластера — до 0.7808; обучение только на SHAP-эмбедингах дало средний ROC-AUC ≈ 0.759 . Flow-компоненты оказались наиболее удачным сжатым представлением: LogReg только на flow-компонентах дала 0.7967, почти как RF на исходных признаках 0.7976, но добавление flow-компонент к исходным признакам не улучшило результат.

Что можно делать дальше

Бизнес

Использовать прогнозы для CRM-кампаний и приоритизации удержания.

Модель

Проверить временную валидацию и калибровку вероятностей.

Данные

Добавить другие внешние данные для расширения набора признаков.